

機械学習 サポートベクターマシン

管理工学科

篠沢佳久


資料の内容

- サポートベクターマシン (SVM: Support Vector Machine)
 - サポートベクター
 - ハードマージン, ソフトマージン
 - カーネル法
- 実習
 - クラス分類: Support Vector Classification (SVC)
 - 回帰: Support Vector Regression (SVR)

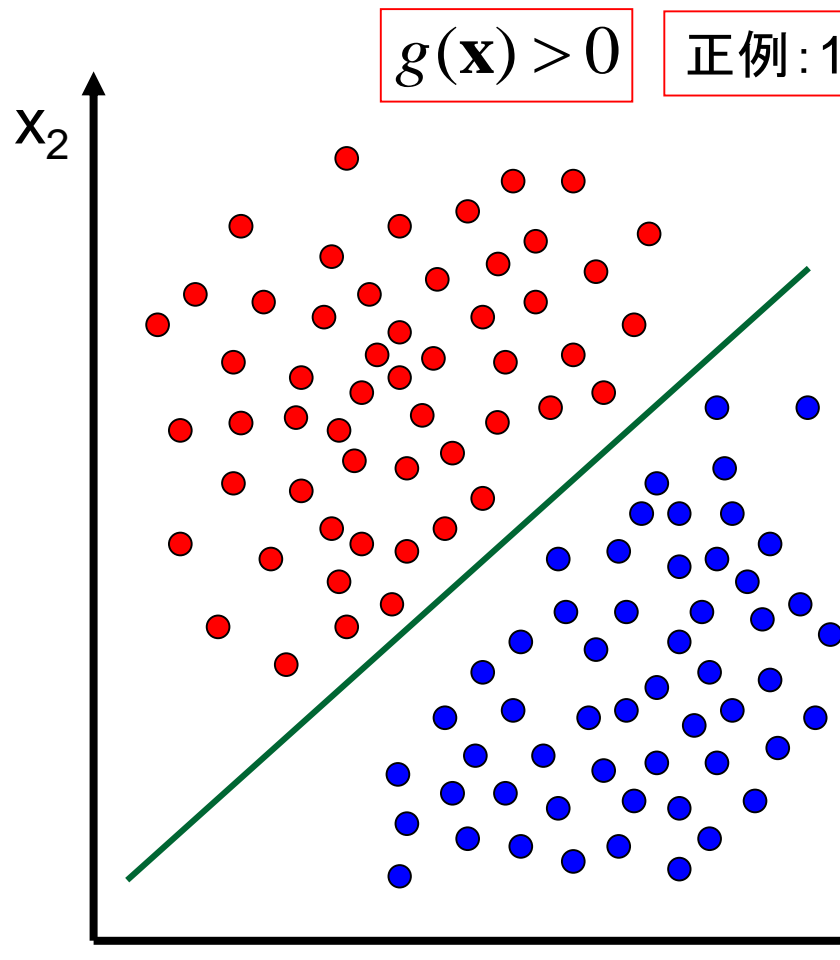
サポートベクターマシン

特徴空間(復習)

- 「8」と「B」の特徴ベクトル(x_1, x_2)を平面上に表現



線形識別関数による二値分類





$$f(\mathbf{x}) = \begin{cases} 1 & g(\mathbf{x}) > 0 \\ 0 & g(\mathbf{x}) < 0 \end{cases}$$

線形識別関数

$$g(\mathbf{x}) = \mathbf{w}^t \mathbf{x} + b$$



境界 ($g(\mathbf{x})=0$) の引き方①

線形分離可能な場合、パーセプトロンにおいては、
無数の境界を引くことが可能





境界 ($g(\mathbf{x})=0$) の引き方②

問題点




境界 ($g(\mathbf{x})=0$) の引き方③

境界を可能な限り全ての点から離す




境界 ($g(x)=0$) の引き方④





境界 ($g(x)=0$) の引き方⑤

全データを考慮すべきか




サポートベクターマシンにおける境界の引き方①

境界に一番近いデータを可能な限り均等に離す




サポートベクターマシンにおける境界の引き方②

境界に一番近いデータを可能な限り均等に離す



マージン①




境界に近いデータ(サポートベクター)との距離
(マージン)が最大になるように、境界線を設定

マージン②

線形識別関数



$$g(\mathbf{x}) = \mathbf{w}^t \mathbf{x} + b$$




マージン m

$$m = \frac{|\mathbf{w}^t \mathbf{x}_1 + b| + |\mathbf{w}^t \mathbf{x}_2 + b|}{\|\mathbf{w}\|}$$
$$= \frac{|b_+| + |b_-|}{\|\mathbf{w}\|}$$

垂線の長さ



マージン③



線形識別関数

$$g(\mathbf{x}) = \mathbf{w}^t \mathbf{x} + b$$

$$b_+ = +1$$

$$b_- = -1$$

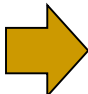


マージン m

$$m = \frac{2}{\|\mathbf{w}\|}$$

定式化(主問題)

- 学習データ: $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$
- 正解ラベル: $y_i \in \{1, -1\}$ ($i=1, 2, \dots, n$)

- 正例: $y_i=1$ のデータ $\rightarrow \mathbf{w}^t \mathbf{x}_i + b \geq 1$
 - 負例: $y_i=-1$ のデータ $\rightarrow \mathbf{w}^t \mathbf{x}_i + b \leq -1$
-  $y_i(\mathbf{w}^t \mathbf{x}_i + b) \geq 1$

主問題


$$\begin{aligned} &\text{Maximize} \quad \frac{2}{\|\mathbf{w}\|} \\ &\text{subject to} \quad y_i(\mathbf{w}^t \mathbf{x}_i + b) \geq 1 \end{aligned}$$

マージン最大化

マージンが最大となるサポートベクターを決める
重み \mathbf{w} を求める

解法①

$$\begin{array}{ll} \text{Maximize} & \frac{2}{\|\mathbf{w}\|} \\ \text{subject to} & y_i(\mathbf{w}^t \mathbf{x}_i + b) \geq 1 \end{array}$$



$$\begin{array}{ll} \text{Minimize} & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{subject to} & y_i(\mathbf{w}^t \mathbf{x}_i + b) \geq 1 \end{array}$$

■ ラグランジュ未定乗数法

ラグランジュ関数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \mathbf{w}^t \mathbf{w} - \sum_i \alpha_i (y_i(\mathbf{w}^t \mathbf{x}_i + b) - 1)$$

①

$$\alpha_i \geq 0$$

②

$$\alpha_i (y_i(\mathbf{w}^t \mathbf{x}_i + b) - 1) = 0$$

③

$$y_i(\mathbf{w}^t \mathbf{x}_i + b) - 1 \geq 0$$

α_i : ラグランジュ定数 (非負)

ラグランジュ未定乗数法(不等式制約条件)

■ 定式化

$$\min_{\mathbf{x}} f(\mathbf{x}) \quad \text{subject to } g_i(\mathbf{x}) \geq 0 \quad \text{for } i = 1, 2, \dots, n$$

- 次式を満たす $\alpha_i \geq 0 (i=1, 2, \dots, n)$ が存在
- カルーシュ・クーン・タッカー条件(KKT)

$$L(\mathbf{x}, \boldsymbol{\alpha}) = f(\mathbf{x}) - \sum_{i=1}^n \alpha_i g_i(\mathbf{x})$$

$$\left. \frac{\partial L(\mathbf{x}, \boldsymbol{\alpha})}{\partial \mathbf{x}} \right|_{\mathbf{x}=\mathbf{x}_0} = 0$$

$$\alpha_i g_i(\mathbf{x}) = 0$$

$$g_i(\mathbf{x}) \geq 0$$

ラグランジュ未定乗数法(不等式制約条件)

■ 定式化

$$\min_{\mathbf{x}} f(\mathbf{x}) \quad \text{subject to } g_i(\mathbf{x}) \geq 0 \quad \text{for } i = 1, 2, \dots, n$$

- 次式を満たす $\alpha_i \geq 0 (i=1, 2, \dots, n)$ が存在 \Rightarrow ① $\alpha_i \geq 0$
- カルーシュ・クーン・タッカー条件(KKT)

$$L(\mathbf{x}, \boldsymbol{\alpha}) = f(\mathbf{x}) - \sum_{i=1}^n \alpha_i g_i(\mathbf{x})$$

ラグランジュ関数

$$\left. \frac{\partial L(\mathbf{x}, \boldsymbol{\alpha})}{\partial \mathbf{x}} \right|_{\mathbf{x}=\mathbf{x}_0} = 0$$

$$\alpha_i g_i(\mathbf{x}) = 0 \Rightarrow$$

②

$$\alpha_i (y_i (\mathbf{w}^t \mathbf{x}_i + b) - 1) = 0$$

$$g_i(\mathbf{x}) \geq 0 \Rightarrow$$


③

$$y_i (\mathbf{w}^t \mathbf{x}_i + b) - 1 \geq 0$$


ラグランジュ乗数の意味①

②

$$\alpha_i (y_i (\mathbf{w}^t \mathbf{x}_i + b) - 1) = 0$$



$$\alpha_i (y_i g(\mathbf{x}_i) - 1) = 0$$



正解ラベル

$$y = -1$$




$$yg(\mathbf{x}) > 1$$



条件式が成立するためには $\alpha = 0$

ラグランジュ乗数の意味②

② $\alpha_i(y_i(\mathbf{w}^t \mathbf{x}_i + b) - 1) = 0 \iff \alpha_i(y_i g(\mathbf{x}_i) - 1) = 0$



正解ラベル

$y = -1$



$y g(\mathbf{x}) = 1$



条件式は成立




$\alpha \geq 0$ (非負)



次頁


$\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$



$\alpha > 0$ となるデータがサポートベクター

解法②

$$\begin{array}{ll} \text{Maximize} & \frac{2}{\|\mathbf{w}\|} \\ \text{subject to} & y_i(\mathbf{w}^t \mathbf{x}_i + b) \geq 1 \end{array}$$



$$\begin{array}{ll} \text{Minimize} & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{subject to} & 1 - y_i(\mathbf{w}^t \mathbf{x}_i + b) \leq 0 \end{array}$$

■ ラグランジュ未定乗数法

α_i : ラグランジュ定数 (非負)

ラグランジュ関数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \mathbf{w}^t \mathbf{w} - \sum_i \alpha_i (y_i(\mathbf{w}^t \mathbf{x}_i + b) - 1)$$

$$\frac{\partial L(\mathbf{w}, b, \boldsymbol{\alpha})}{\partial \mathbf{w}} = \mathbf{w} - \sum_i \alpha_i y_i \mathbf{x}_i = 0 \quad \frac{\partial L(\mathbf{w}, b, \boldsymbol{\alpha})}{\partial b} = \sum_i \alpha_i y_i = 0$$

$$\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$$

α_i が求まれば \mathbf{w} も求まる

解法③

ラグランジュ関数

$$\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$$

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \mathbf{w}^t \mathbf{w} - \sum_i \alpha_i (y_i (\mathbf{w}^t \mathbf{x}_i + b) - 1)$$

$$= \frac{1}{2} \left(\sum_i \alpha_i y_i \mathbf{x}_i \right)^t \left(\sum_j \alpha_j y_j \mathbf{x}_j \right) - \sum_i \alpha_i \left(y_i \left(\sum_j \alpha_j y_j \mathbf{x}_j^t \mathbf{x}_i + b \right) - 1 \right)$$

$$= \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^t \mathbf{x}_j - \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^t \mathbf{x}_j - b \sum_i \alpha_i y_i + \sum_i \alpha_i$$

$$= \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^t \mathbf{x}_j$$



$$L'(\boldsymbol{\alpha}) = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^t \mathbf{x}_j$$

$\boldsymbol{\alpha}$ のみの目的関数

$$\sum_i \alpha_i y_i = 0$$

双対問題①

■ 双対問題

□ 新しい目的関数の最大化

$$\begin{aligned} \text{Maximize } L'(\boldsymbol{\alpha}) &= \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^t \mathbf{x}_j \\ \text{subject to } \alpha_i &\geq 0, \sum_i \alpha_i y_i = 0 \end{aligned}$$


□ 二次計画問題

- α_i を求める解法
- SMO(sequential minimal optimization)によって求める

双対問題②

主問題

$$\begin{aligned} &\text{Maximize} \quad \frac{2}{\|\mathbf{w}\|} \\ &\text{subject to} \quad y_i(\mathbf{w}^t \mathbf{x}_i + b) \geq 1 \end{aligned}$$



双対問題

$$\begin{aligned} &\text{Maximize} \quad L'(\boldsymbol{\alpha}) = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^t \mathbf{x}_j \\ &\text{subject to} \quad \alpha_i \geq 0, \sum_i \alpha_i y_i = 0 \end{aligned}$$

- 主問題
 - \mathbf{w} を求めた後, α_i を求める
- 双対問題
 - α_i を求めた後, \mathbf{w} を求める

$$\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$$

二次計画問題 (Quadratic programming)

- SVMの場合の解法
 - SMO (Sequential Minimal Optimization)

α_i の求め方

α_i ($i=1,2,\dots,n$) を初期化

while KKTを満たさない α_i が存在:

 KKTを満たさない α_1 を選択

 別の α_2 を選択

 目的関数が改善されるように α_1 と α_2 を更新

*従って, SVMで解を求めるには計算時間がかかります

解法④

α_i の多くはゼロ

$$\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$$


- $\alpha_i > 0$ のデータがサポートベクター
- S 個のサポートベクター: \mathbf{x}_{t_j} ($j=1, 2, \dots, S$)

$$\mathbf{w} = \sum_{j=1}^S \alpha_{t_j} y_{t_j} \mathbf{x}_{t_j}$$

- 正例のサポートベクター: \mathbf{x}_+ $\mathbf{w}^t \mathbf{x}_+ + b = 1$
- 負例のサポートベクター: \mathbf{x}_- $\mathbf{w}^t \mathbf{x}_- + b = -1$

$$b = -\frac{1}{2} (\mathbf{w}^t \mathbf{x}_+ + \mathbf{w}^t \mathbf{x}_-)$$

未知データの予測



① SMOによって α_i を求める



② $g(x)$ を求める

$$\mathbf{w} = \sum_{j=1}^s \alpha_{t_j} y_{t_j} \mathbf{x}_{t_j}$$

$$b = -\frac{1}{2} (\mathbf{w}^t \mathbf{x}_+ + \mathbf{w}^t \mathbf{x}_-)$$




③ 未知データ \mathbf{z} の予測

$g(\mathbf{z}) = \mathbf{w}^t \mathbf{z} + b > 0 \rightarrow$ 正例

$g(\mathbf{z}) = \mathbf{w}^t \mathbf{z} + b < 0 \rightarrow$ 負例

ソフトマージン

条件の緩和(ソフトマージン)



ソフトマージンの定式化

- 学習データ: $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$
- 正解ラベル: $y_i \in \{1, -1\}$ ($i=1, 2, \dots, n$)

- 正例: $y_i=1$ のデータ $\rightarrow \mathbf{w}^t \mathbf{x}_i + b \geq 1 - \xi_i$
- 負例: $y_i=-1$ のデータ $\rightarrow \mathbf{w}^t \mathbf{x}_i + b \leq -1 + \xi_i$

$$y_i(\mathbf{w}^t \mathbf{x}_i + b) \geq 1 - \xi_i$$
$$\xi_i \geq 0$$

主問題

$$\begin{aligned} &\text{Minimize} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \\ &\text{subject to} \quad y_i(\mathbf{w}^t \mathbf{x}_i + b) \geq 1 - \xi_i, \xi_i \geq 0 \end{aligned}$$

C: 定数

$$\text{Minimize} \quad \sum_{i=1}^n \xi_i$$

「誤り」の二乗和を最小

ソフトマージンの解法①

$$\begin{aligned} &\text{Minimize} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \\ &\text{subject to} \quad y_i (\mathbf{w}^t \mathbf{x}_i + b) \geq 1 - \xi_i, \xi_i \geq 0 \end{aligned}$$

■ ラグランジュ未定乗数法

ラグランジュ関数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}, \mathbf{v}, \boldsymbol{\xi}) = \frac{1}{2} \mathbf{w}^t \mathbf{w} + C \sum_i \xi_i - \sum_i \alpha_i (y_i (\mathbf{w}^t \mathbf{x}_i + b) - 1 + \xi_i) - \sum_i \nu_i \xi_i$$

$$\alpha_i \geq 0$$

$$\alpha_i (y_i (\mathbf{w}^t \mathbf{x}_i + b) - 1 + \xi_i) = 0$$

$$y_i (\mathbf{w}^t \mathbf{x}_i + b) - 1 + \xi_i \geq 0$$

$$\nu_i \geq 0$$

$$\nu_i \xi_i = 0$$

$$\xi_i \geq 0$$

α_i, ν_i : ラグランジュ定数

ソフトマージンの解法②

$$\begin{aligned} &\text{Minimize} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \\ &\text{subject to} \quad y_i (\mathbf{w}^t \mathbf{x}_i + b) \geq 1 - \xi_i, \xi_i \geq 0 \end{aligned}$$

■ ラグランジュ未定乗数法

ラグランジュ関数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}, \mathbf{v}, \boldsymbol{\xi}) = \frac{1}{2} \mathbf{w}^t \mathbf{w} + C \sum_i \xi_i - \sum_i \alpha_i (y_i (\mathbf{w}^t \mathbf{x}_i + b) - 1 + \xi_i) - \sum_i \nu_i \xi_i$$

$$\frac{\partial L(\mathbf{w}, b, \boldsymbol{\alpha}, \mathbf{v}, \boldsymbol{\xi})}{\partial \mathbf{w}} = \mathbf{w} - \sum_i \alpha_i y_i \mathbf{x}_i = 0 \quad \Rightarrow \quad \mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$$

$$\frac{\partial L(\mathbf{w}, b, \boldsymbol{\alpha}, \mathbf{v}, \boldsymbol{\xi})}{\partial b} = \sum_i \alpha_i y_i = 0 \qquad \frac{\partial L(\mathbf{w}, b, \boldsymbol{\alpha}, \mathbf{v}, \boldsymbol{\xi})}{\partial \xi_i} = C - \alpha_i - \nu_i = 0$$

ソフトマージンの解法③

ラグランジュ関数

$$\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$$

$$L(\mathbf{w}, b, \boldsymbol{\alpha}, \mathbf{v}, \boldsymbol{\xi})$$

$$= \frac{1}{2} \mathbf{w}^t \mathbf{w} + C \sum_i \xi_i - \sum_i \alpha_i (y_i (\mathbf{w}^t \mathbf{x}_i + b) - 1 + \xi_i) - \sum_i v_i \xi_i$$

$$= \frac{1}{2} \left(\sum_i \alpha_i y_i \mathbf{x}_i \right)^t \left(\sum_j \alpha_j y_j \mathbf{x}_j \right) + C \sum_i \xi_i - \sum_i \alpha_i \left(y_i \left(\sum_j \alpha_j y_j \mathbf{x}_j^t \mathbf{x}_i + b \right) - 1 + \xi_i \right) - \sum_i v_i \xi_i$$

$$= \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^t \mathbf{x}_j + C \sum_i \xi_i - \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^t \mathbf{x}_j - b \sum_i \alpha_i y_i + \sum_i \alpha_i - \sum_i \alpha_i \xi_i - \sum_i v_i \xi_i$$

$$= \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^t \mathbf{x}_j - b \sum_i \alpha_i y_i + \sum_i (C - \alpha_i - v_i) \xi_i$$

$$C - \alpha_i - v_i = 0$$

$$\sum_i \alpha_i y_i = 0$$



$$L'(\boldsymbol{\alpha}) = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^t \mathbf{x}_j$$

$\boldsymbol{\alpha}_i$ のみの目的関数

ソフトマージンにおける双対問題

■ 双対問題

□ 新しい目的関数の最大化

$$\begin{aligned} \text{Maximize } L'(\boldsymbol{\alpha}) &= \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^t \mathbf{x}_j \\ \text{subject to } C &\geq \alpha_i \geq 0, \sum_i \alpha_i y_i = 0 \end{aligned}$$

- ハードマージンにおける双対問題とほぼ同じ
- ラグランジュ乗数 α_i に上限値(C)が存在
- SMOを用いて α_i を求める

$$C - \alpha_i - \nu_i = 0, \nu_i \geq 0 \quad \Rightarrow \quad C \geq \alpha_i \geq 0$$

ソフトマージンの解法⑤

α_i の多くはゼロ

$$\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$$

- $\alpha_i > 0$ のデータがサポートベクター
- S 個のサポートベクター: \mathbf{x}_{t_j} ($j=1, 2, \dots, S$)

$$\mathbf{w} = \sum_{j=1}^S \alpha_{t_j} y_{t_j} \mathbf{x}_{t_j}$$

- 正例のサポートベクター: \mathbf{x}_+ $\mathbf{w}^t \mathbf{x}_+ + b = 1$
- 負例のサポートベクター: \mathbf{x}_- $\mathbf{w}^t \mathbf{x}_+ + b = -1$

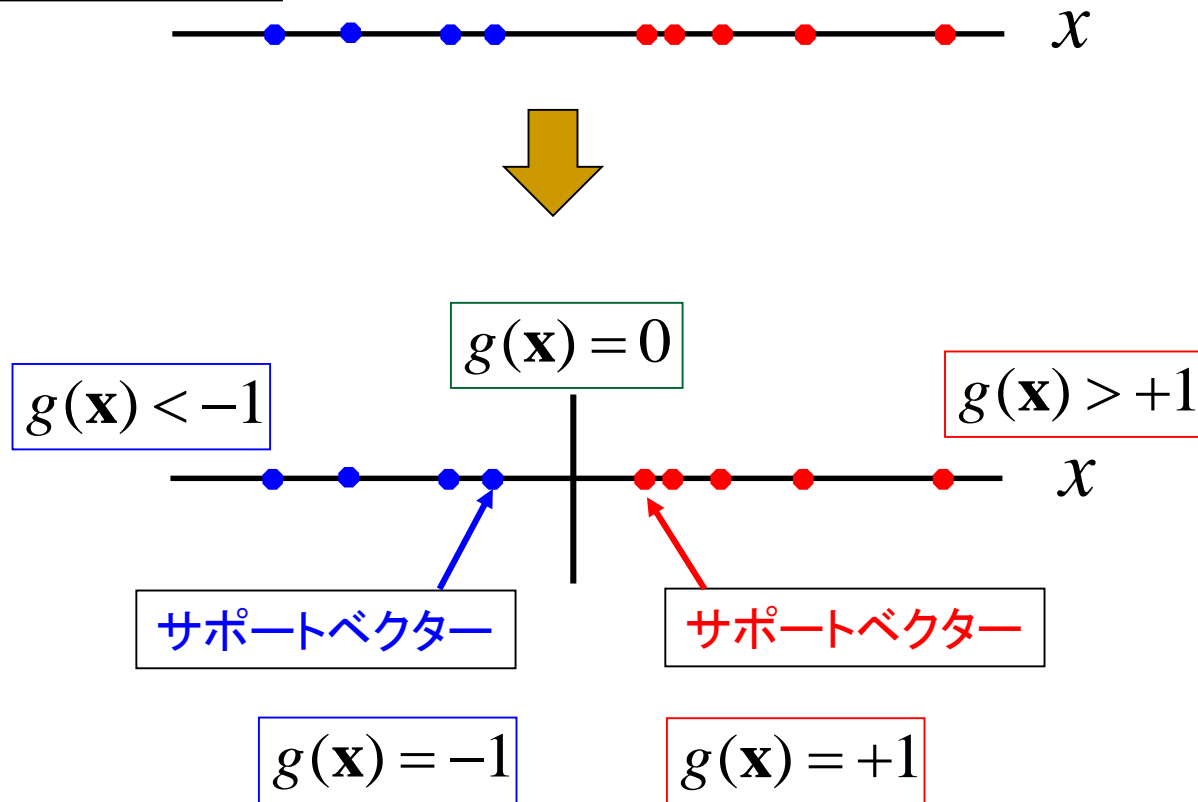
$$b = -\frac{1}{2} (\mathbf{w}^t \mathbf{x}_+ + \mathbf{w}^t \mathbf{x}_-)$$

カーネル法

線形分離不可能な問題への対応①

線形分離可能な場合


一次元の特徴量



線形分離不可能な問題への対応②


線形分離不可能な場合

一次元の特徴量



(x, x^2) に変換


二次元の特徴量




線形分離不可能な問題への対応③

線形分離不可能な場合

一次元の特徴量




二次元の特徴量



高次元特徴空間への写像

■ 非線形写像 $\phi(\mathbf{x})$

□ データ \mathbf{x} を高次元空間 F に変換



高次元空間特徴に写像した場合の定式化

- 学習データ: $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$
 - 非線形写像 $\phi(\mathbf{x})$
 - 正解ラベル: $y_i \in \{1, -1\}$ ($i=1, 2, \dots, n$)
 - 正例: $y_i=1$ のデータ $\rightarrow \mathbf{w}^t \phi(\mathbf{x}_i) + b \geq 1$
 - 負例: $y_i=-1$ のデータ $\rightarrow \mathbf{w}^t \phi(\mathbf{x}_i) + b \leq -1$
- ➡ $y_i(\mathbf{w}^t \phi(\mathbf{x}_i) + b) \geq 1$

主問題

$$\begin{aligned} &\text{Maximize} \quad \frac{2}{\|\mathbf{w}\|} \\ &\text{subject to} \quad y_i(\mathbf{w}^t \phi(\mathbf{x}_i) + b) \geq 1 \end{aligned}$$

マージン最大化

解法: $\mathbf{x} \rightarrow \Phi(\mathbf{x})$ と変わったのみで, 同じ手順で解く

高次元空間特徴に写像した場合の解法①

■ 主問題のラグランジュ関数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \mathbf{w}^t \mathbf{w} - \sum_i \alpha_i (y_i (\mathbf{w}^t \mathbf{x}_i + b) - 1)$$



$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \mathbf{w}^t \mathbf{w} - \sum_i \alpha_i (y_i (\mathbf{w}^t \phi(\mathbf{x}_i) + b) - 1)$$

■ 双対問題のラグランジュ関数

$$L'(\boldsymbol{\alpha}) = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^t \mathbf{x}_j$$



$$L'(\boldsymbol{\alpha}) = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^t \phi(\mathbf{x}_j)$$

高次元空間特徴に写像した場合の解法②

■ 双対問題

$$\begin{aligned} \text{Maximize} \quad & L'(\boldsymbol{\alpha}) = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^t \phi(\mathbf{x}_j) \\ \text{subject to} \quad & \alpha_i \geq 0, \sum_i \alpha_i y_i = 0 \end{aligned}$$

■ α_i をSMOによって求めた後, \mathbf{w} を求める

$$\mathbf{w} = \sum_i \alpha_i y_i \phi(\mathbf{x}_i)$$

$$b = -\frac{1}{2} (\mathbf{w}^t \phi(\mathbf{x}_+) + \mathbf{w}^t \phi(\mathbf{x}_-))$$

$\mathbf{x}_+, \mathbf{x}_-$: サポートベクター

カーネル法

写像Φはどのようにすればよいのか

- 双対問題のラグランジュ関数

$$L'(\alpha) = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^t \phi(\mathbf{x}_j)$$

高次元特徴空間に変換し、内積を計算するため
多くの計算量が必要

$K(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^t \phi(\mathbf{x}_j)$ となる関数Kを用いる

K:カーネル関数

カーネル関数の例①

$$\mathbf{x}^t = (x_1, x_2)$$

元のデータ: 2次元

$$\phi(\mathbf{x}) = (1, x_1^2, \sqrt{2}x_1x_2, x_2^2, \sqrt{2}x_1, \sqrt{2}x_2)^t$$

2次元から6次元への変換

$$K(\mathbf{x}_i, \mathbf{x}_j) = (1 + \mathbf{x}_i^t \mathbf{x}_j)^2$$

カーネル関数(多項式カーネル)



$$K(\mathbf{x}_i, \mathbf{x}_j) = (1 + \mathbf{x}_i^t \mathbf{x}_j)^2$$

$$= (1 + x_{i1}x_{j1} + x_{i2}x_{j2})^2$$

$$= 1 + x_{i1}^2x_{j1}^2 + 2x_{i1}x_{j1}x_{i2}x_{j2} + x_{i2}^2x_{j2}^2 + 2x_{i1}x_{j1} + 2x_{i2}x_{j2}$$

$$= (1, x_{i1}^2, \sqrt{2}x_{i1}x_{i2}, x_{i2}^2, \sqrt{2}x_{i1}, \sqrt{2}x_{i2})(1, x_{j1}^2, \sqrt{2}x_{j1}x_{j2}, x_{j2}^2, \sqrt{2}x_{j1}, \sqrt{2}x_{j2})^t$$

$$= \phi(\mathbf{x}_i)^t \phi(\mathbf{x}_j)$$

元のデータでこの式を計算

→ 元のデータを6次元に変換し、内積を計算したことと同じ
(カーネルトリック)

カーネル関数の例②

$$L'(\mathbf{a}) = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^t \phi(\mathbf{x}_j)$$

$$\phi(\mathbf{x}_i)^t \phi(\mathbf{x}_j)$$

高次元空間に変換→内積計算

$$= (1, x_{i1}^2, \sqrt{2}x_{i1}x_{i2}, x_{i2}^2, \sqrt{2}x_{i1}, \sqrt{2}x_{i2})(1, x_{j1}^2, \sqrt{2}x_{j1}x_{j2}, x_{j2}^2, \sqrt{2}x_{j1}, \sqrt{2}x_{j2})^t$$

$$= 1 + x_{i1}^2 x_{j1}^2 + 2x_{i1}x_{j1}x_{i2}x_{j2} + x_{i2}^2 x_{j2}^2 + 2x_{i1}x_{j1} + 2x_{i2}x_{j2}$$

$$L'(\mathbf{a}) = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j)$$

カーネル関数を用いた場合

$$K(\mathbf{x}_i, \mathbf{x}_j) = (1 + \mathbf{x}_i^t \mathbf{x}_j)^2$$

$$= (1 + x_{i1}x_{j1} + x_{i2}x_{j2})^2$$

高次元空間に変換しなくてよい
(Φすら知らなくてもよい)

$$= 1 + x_{i1}^2 x_{j1}^2 + 2x_{i1}x_{j1}x_{i2}x_{j2} + x_{i2}^2 x_{j2}^2 + 2x_{i1}x_{j1} + 2x_{i2}x_{j2}$$

カーネル関数の例③

- 線形カーネル

$$K(\mathbf{x}, \mathbf{y}) = \mathbf{x}^t \mathbf{y}$$

- 多項式カーネル

$$K(\mathbf{x}, \mathbf{y}) = (1 + \mathbf{x}^t \mathbf{y})^p$$

- ガウシアンカーネル (RBFカーネル)

$$K(\mathbf{x}, \mathbf{y}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{y}\|^2}{2\sigma^2}\right)$$


- シグモイドカーネル

$$K(\mathbf{x}, \mathbf{y}) = \tanh(\alpha \mathbf{x}^t \mathbf{y} + \beta)$$

カーネル法の意味

- 非線形写像 $\phi(\mathbf{x})$

- データ \mathbf{x} を高次元空間 F に変換



- 非線形写像 $\phi(\mathbf{x})$ を直接使いなくとも、カーネル関数により、高次元空間に写像したことになる(カーネルトリック)

未知データの予測①

未知データ \mathbf{z} の予測

$$\begin{aligned} g(\mathbf{z}) &= \mathbf{w}^t \phi(\mathbf{z}) + b \quad \leftarrow \mathbf{w} = \sum_i \alpha_i y_i \phi(\mathbf{x}_i) \\ &= \sum_i \alpha_i y_i \phi(\mathbf{x}_i)^t \phi(\mathbf{z}) + b \\ &= \sum_i \alpha_i y_i K(\mathbf{x}_i, \mathbf{z}) + b \end{aligned}$$

サポートベクターとのカーネル関数を計算

$$g(\mathbf{z}) = \mathbf{w}^t \phi(\mathbf{z}) + b > 0 \rightarrow \text{正例}$$

$$g(\mathbf{z}) = \mathbf{w}^t \phi(\mathbf{z}) + b < 0 \rightarrow \text{負例}$$

未知データの予測②

$\mathbf{x}_+, \mathbf{x}_-$: サポートベクター

$$\mathbf{w} = \sum_i \alpha_i y_i \phi(\mathbf{x}_i)$$

$$\mathbf{w}^t \phi(\mathbf{x}_+) + b = 1$$

$$\mathbf{w}^t \phi(\mathbf{x}_-) + b = 1$$

$$\sum_i \alpha_i y_i \phi(\mathbf{x}_i)^t \phi(\mathbf{x}_+) + b = 1$$

$$\sum_i \alpha_i y_i \phi(\mathbf{x}_i)^t \phi(\mathbf{x}_-) + b = 1$$

$$\sum_i \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}_+) + b = 1$$

$$\sum_i \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}_-) + b = 1$$

$$b = -\frac{1}{2} \left(\sum_i \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}_+) + \sum_i \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}_-) \right)$$

クラス分類問題と回帰問題

クラス分類問題と回帰問題

- クラス分類問題

- Support Vector Classification (SVC)

- 回帰問題


- Support Vector Regression (SVR)

多クラス分類問題への対応

- SVMは二クラス分類問題
- 多クラス分類問題
 - 「1対1」(one-versus-one)による方法
 - 「1対その他」(one-versus-rest)による方法

「1対1による方法」①



- クラス数が3個の場合
 - 特徴ベクトルは2次元




τ_{ij}
クラス ω_i とクラス ω_j を分ける線形識別関数

クラス数が n 個の場合
 nC_2 の線形識別関数

「1対1による方法」②



「1対1による方法」③




「1対1による方法」④

- クラス数が n 個の場合
 - 二つのデータを分離する線形識別関数を ${}_nC_2$ 個求める
 - 予測したいデータがどちらに属するか, ${}_nC_2$ 個の線形識別関数において調べる
 - クラス数が多くなった場合, 解に矛盾が生じる
 - 多数決によって最終的に解を決める場合もある

「1対その他による方法」①

- クラス数が3個の場合
 - 特徴ベクトルは2次元




τ_i


クラス ω_i とその他のクラスを分ける
線形識別関数

クラス数が n 個の場合
 n 個の線形識別関数

「1対その他による方法」②

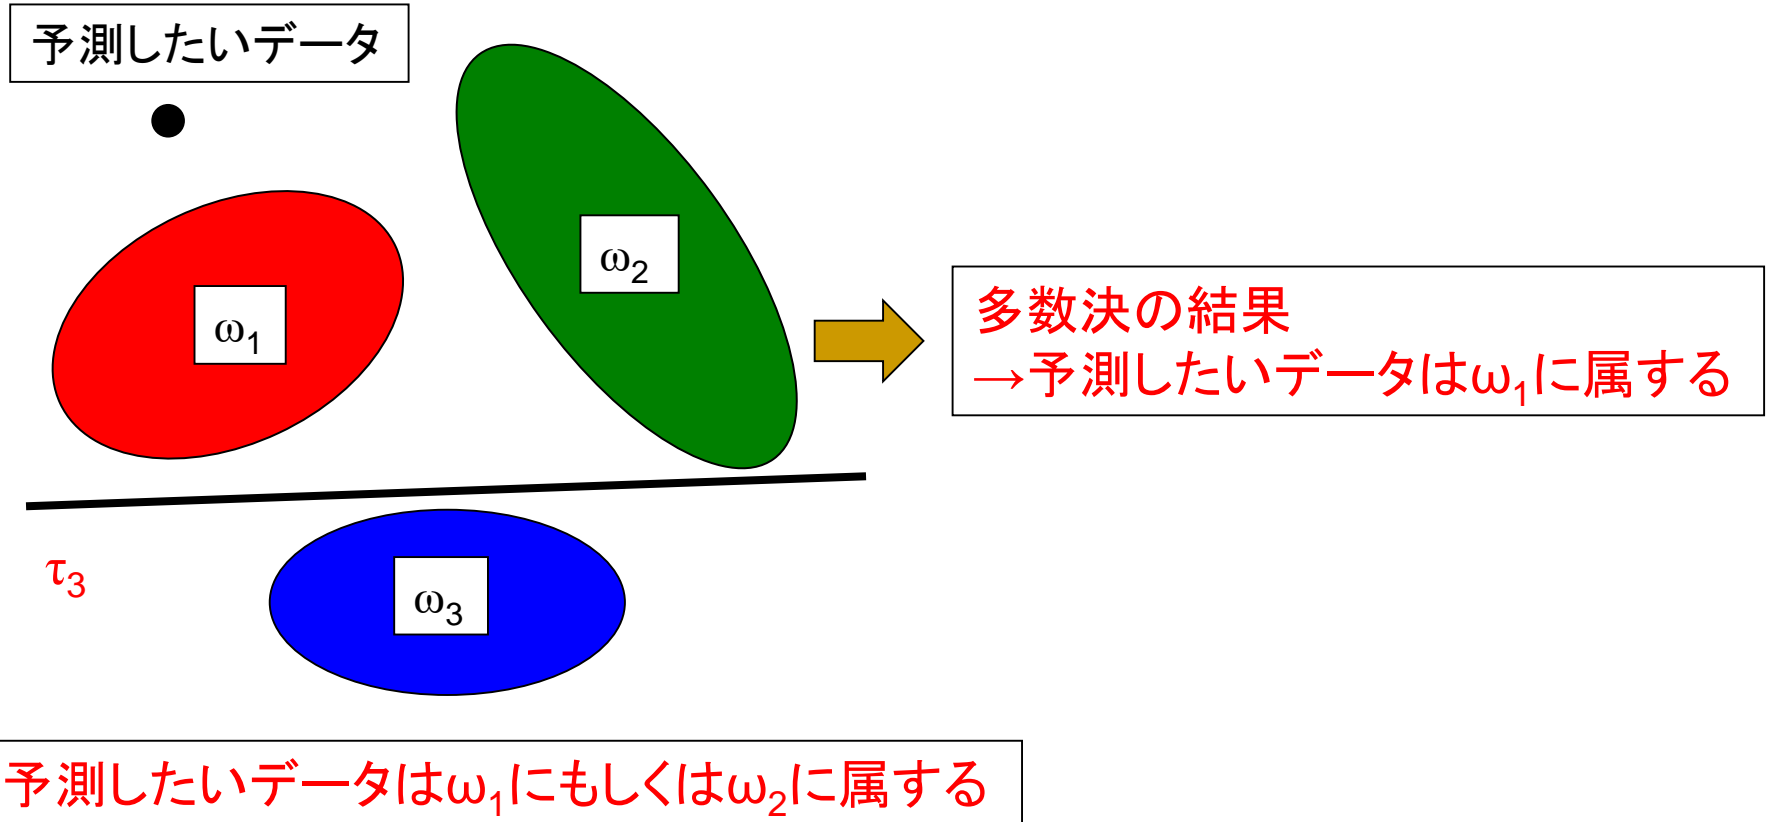


予測したいデータは ω_1 に属する



予測したいデータは ω_1 もしくは ω_3 に属する

「1対その他による方法」③



「1対その他による方法」④

■ クラス数が n 個の場合



- 任意のクラスとその他のクラスを分離する線形識別関数を n 個求める
- 予測したいデータがどちらに属するか, n 個の線形識別関数において調べる
- クラス数が多くなった場合, 解に矛盾が生じる
- 多数決によって最終的に解を決める場合もある

回帰問題への対応


- 入力データ: $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$
- 正解データ: y_1, y_2, \dots, y_n

高次元空間への写像: Φ

- 回帰モデル $g(\mathbf{x}) = \mathbf{w}^t \phi(\mathbf{x}) + b$



ペナルティを与える




ϵ インセンシティブ
この領域内*のデータには
ペナルティを与えない

ペナルティを与える

* ϵ -tubeと呼ばれています

ε インセンシティブ損失関数①



最小化 $\sum_{i=1}^n (g(\mathbf{x}_i) - y_i)^2 + \lambda \|\mathbf{w}\|^2$

誤差項

正規化項


最小化 $C \sum_{i=1}^n E_{\varepsilon}(g(\mathbf{x}_i) - y_i) + \frac{1}{2} \|\mathbf{w}\|^2$

E_{ε} : ε インセンシティブ損失関数
 ε -tubeから外れたデータにペナルティを与える




ε インセンシティブ損失関数②

$$\text{最小化 } C \sum_{i=1}^n E_{\varepsilon}(g(\mathbf{x}_i) - y_i) + \frac{1}{2} \|\mathbf{w}\|^2$$

$$E_{\varepsilon}(r) = \begin{cases} 0 & \text{if } |r| < \varepsilon \\ |r| - \varepsilon & \text{otherwise} \end{cases}$$



ソフトマージン(スラック変数の導入)



$$g(\mathbf{x}_i) - \varepsilon \leq y_i \leq g(\mathbf{x}_i) + \varepsilon$$

外れ値にはペナルティを与える

スラック変数 ξ^+ , ξ^-


$$\xi_i^+ = \begin{cases} y_i - \varepsilon - g(\mathbf{x}_i) & y_i > g(\mathbf{x}_i) + \varepsilon \\ 0 & \text{otherwise} \end{cases}$$
$$\xi_i^- = \begin{cases} g(\mathbf{x}_i) - y_i - \varepsilon & y_i < g(\mathbf{x}_i) - \varepsilon \\ 0 & \text{otherwise} \end{cases}$$



$$g(\mathbf{x}_i) - \varepsilon - \xi_i^- \leq y_i \leq g(\mathbf{x}_i) + \varepsilon + \xi_i^+$$

ξ^+ , ξ^- を最小

ソフトマージンによる定式化



$$g(\mathbf{x}_i) - \epsilon - \xi_i^- \leq y_i \leq g(\mathbf{x}_i) + \epsilon + \xi_i^+$$

ξ^+, ξ^- を最小

主問題

$$\text{minimize } C \sum_{i=1}^n (\xi_i^+ + \xi_i^-) + \frac{1}{2} \|\mathbf{w}\|^2$$

$$\text{subject to } g(\mathbf{x}_i) - \epsilon - \xi_i^- \leq y_i \leq g(\mathbf{x}_i) + \epsilon + \xi_i^+$$

$$\xi_i^- \geq 0, \xi_i^+ \geq 0$$

SVRの解法①

ラグランジュ関数

$$\begin{aligned} & \lambda(\mathbf{w}, b, \xi_i^+, \xi_i^-, \mu_i^+, \mu_i^-, \alpha_i^+, \alpha_i^-) \\ &= C \sum_{i=1}^n (\xi_i^+ + \xi_i^-) + \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n (\mu_i^+ \xi_i^+ + \mu_i^- \xi_i^-) - \sum_{i=1}^n \alpha_i^+ (\varepsilon + \xi_i^+ + g(\mathbf{x}_i) - y_i) - \sum_{i=1}^n \alpha_i^- (\varepsilon + \xi_i^- - g(\mathbf{x}_i) + y_i) \end{aligned}$$

KKT条件

$$\mu_i^+ \geq 0$$

$$\mu_i^+ \xi_i^+ = 0$$

$$\xi_i^+ \geq 0$$

$$\mu_i^- \geq 0$$

$$\mu_i^- \xi_i^- = 0$$

$$\xi_i^- \geq 0$$

$$\alpha_i^+ \geq 0$$

$$\alpha_i^+ (\varepsilon + \xi_i^+ + g(\mathbf{x}_i) - y_i) = 0$$

$$\varepsilon + \xi_i^+ + g(\mathbf{x}_i) - y_i \geq 0$$

$$\alpha_i^- \geq 0$$

$$\alpha_i^- (\varepsilon + \xi_i^- - g(\mathbf{x}_i) + y_i) = 0$$

$$\varepsilon + \xi_i^- - g(\mathbf{x}_i) + y_i \geq 0$$

ラグランジュ定数(非負)

$$\mu_i^+, \mu_i^-, \alpha_i^+, \alpha_i^-$$

SVRの解法②

ラグランジュ関数

$$\begin{aligned} & \lambda(\mathbf{w}, b, \xi_i^+, \xi_i^-, \mu_i^+, \mu_i^-, \alpha_i^+, \alpha_i^-) \\ &= C \sum_{i=1}^n (\xi_i^+ + \xi_i^-) + \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n (\mu_i^+ \xi_i^+ + \mu_i^- \xi_i^-) - \sum_{i=1}^n \alpha_i^+ (\varepsilon + \xi_i^+ + g(\mathbf{x}_i) - y_i) - \sum_{i=1}^n \alpha_i^- (\varepsilon + \xi_i^- - g(\mathbf{x}_i) + y_i) \end{aligned}$$

$$\frac{\partial \lambda}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w} = \sum_{i=1}^n (\alpha_i^+ - \alpha_i^-) \phi(\mathbf{x}_i)$$

$$\frac{\partial \lambda}{\partial \xi_i^+} = 0 \Rightarrow \alpha_i^+ + \mu_i^+ = C$$

ラグランジュ定数(非負)

$$\mu_i^+, \mu_i^-, \alpha_i^+, \alpha_i^-$$

$$\frac{\partial \lambda}{\partial b} = 0 \Rightarrow \sum_{i=1}^n (\alpha_i^+ - \alpha_i^-) = 0$$

$$\frac{\partial \lambda}{\partial \xi_i^-} = 0 \Rightarrow \alpha_i^- + \mu_i^- = C$$

双対問題



カーネル関数

最大化

$$\lambda'(\alpha_i^+, \alpha_i^-) = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\alpha_i^+ - \alpha_i^-)(\alpha_j^+ - \alpha_j^-) K(\mathbf{x}_i, \mathbf{x}_j) - \varepsilon \sum_{i=1}^n (\alpha_i^+ + \alpha_i^-) + \sum_{i=1}^n (\alpha_i^+ - \alpha_i^-) y_i$$

$$\text{subject to } 0 \leq \alpha_i^+ \leq C, 0 \leq \alpha_i^- \leq C, \sum_{i=1}^n (\alpha_i^+ - \alpha_i^-) = 0$$

SVRの解法③

- 二次計画問題を解き, α^+ , α^- を求める



\mathbf{w} , b を求める

$$\mathbf{w} = \sum_{i=1}^n (\alpha_i^+ - \alpha_i^-) \phi(\mathbf{x}_i)$$

$$b_+ = y_+ - \mathbf{w}^t \phi(\mathbf{x}_+) - \varepsilon$$
$$b_- = y_- - \mathbf{w}^t \phi(\mathbf{x}_-) + \varepsilon$$

$$b = \frac{1}{2} (b_+ + b_-)$$

\mathbf{x}_+ : ε -tubeの上限のデータ
 \mathbf{x}_- : ε -tubeの下限のデータ


回帰式



$$g(\mathbf{x}_j) = \mathbf{w}^t \phi(\mathbf{x}_j) + b = \sum_{i=1}^n (\alpha_i^+ - \alpha_i^-) \phi(\mathbf{x}_i)^t \phi(\mathbf{x}_j) + b$$
$$= \sum_{i=1}^n (\alpha_i^+ - \alpha_i^-) K(\mathbf{x}_i, \mathbf{x}_j) + b$$

カーネル関数

サポートベクター



$$\mathbf{w} = \sum_{i=1}^n (\alpha_i^+ - \alpha_i^-) \phi(\mathbf{x}_i)$$

0でない場合, \mathbf{w} の計算に利用



$\alpha^+ > 0$ もしくは $\alpha^- > 0$ となるデータがサポートベクター

サポートベクターマシンのプログラム

SVM Classification (Iris dataset)

SVM Regression (近似曲線)

Support Vector Classification (SVC) のプログラム (Iris_SVC.py)

- Irisデータセット
 - アヤメの分類問題

用途	クラス分類
データ数	150
特徴量	4
目的変数	3

クラス名	データ数
setosa	50
versicolor	50
virginica	50




SVMによる多クラス分類問題①

- SVMは二クラス分類問題を対象
- 多クラス分類問題の場合
 - 一対一 (one versus one)*
 - 3クラスの場合, 3個のモデルを学習
 - ① クラス1とクラス2を分類するSVM
 - ② クラス1とクラス3を分類するSVM
 - ③ クラス2とクラス3を分類するSVM
 - Nクラスの場合 → $_NC_2$ 個のモデルを学習

*scikit-learnのSVCの場合です. 一対多 (one versus other) のモデルもあります

SVMによる多クラス分類問題②

3個の学習済みSVMモデル



統合
予測結果

Iris_SVC.py

```
import numpy
from sklearn import datasets
from sklearn.model_selection import train_test_split
from sklearn.svm import SVC
from sklearn.metrics import classification_report, accuracy_score,
confusion_matrix
```

SVCのために必要

データのロード

```
iris = datasets.load_iris()
```

irisデータセットの読み込み

種類

```
name = iris.target_names
```

```
label = iris.target
```

label
目的変数の値(0,1,2)

個数
150

特徴量

```
feature_names = iris.feature_names
```

```
data = iris.data
```

data
特徴量

大きさ
(150,4)

学習データ, テストデータ

ホールドアウト法

```
train_data, test_data, train_label, test_label = train_test_split(data, label,  
test_size=0.5, random_state=None)
```

多項式カーネル

kernel='poly'
多項式カーネル

gamma:
カーネル関数のパラメータ

```
model = SVC(kernel='poly', C=1, gamma=0.1, probability=True)
```

学習

Cが小さい→ソフトマージン
Cが大きい→ハードマージン

probability=True
→ predict_probaの計算が可能

```
model.fit(train_data, train_label)
```

予測

```
predict = model.predict(test_data)
```

```
predict_proba = model.predict_proba(test_data)
```

サポートベクターの表示

```
print( " [ Support Vector ] " )
```

```
for i in range(3):
```

```
    print( i , ":" , model.n_support_[i] )
```

```
print( model.support_ )
```

n_support_
サポートベクターの個数

support_
サポートベクターのデータの番号

```
from sklearn.svm import SVC
```

```
model = SVC(kernel='poly', C=1, gamma=0.1, probability=True)
```

kernel='poly'
多項式カーネル

Cが小さい→ソフトマージン
Cが大きい→ハードマージン

gamma:
カーネル関数のパラメータ

線形カーネル: kernel='linear'
RBFカーネル: kernel='rbf'
多項式: kernel='poly'
シグモイド: kernel='sigmoid'
デフォルトはRBFカーネル

probability=True
→ predict_probaの計算が可能

```
model = SVC()
```

```
model = SVC(kernel='rbf', C=1, gamma=0.1, probability=True)
```

カーネル関数のパラメータ

■ パラメータ

- degree, gamma, coef0

- 多項式カーネル

$$K(\mathbf{x}, \mathbf{y}) = (\text{coef0} + \text{gamma} \times \mathbf{x}^t \mathbf{y})^{\text{degree}}$$

- RBFカーネル

$$K(\mathbf{x}, \mathbf{y}) = \exp(-\text{gamma} \times \|\mathbf{x} - \mathbf{y}\|^2)$$

- シグモイドカーネル

$$K(\mathbf{x}, \mathbf{y}) = \tanh(\text{gamma} \times \mathbf{x}^t \mathbf{y} + \text{coef0})$$

予測結果の表示

```
print( "¥n setosa versicolor virginica -> 予測結果：正解ラベル" )
for i in range(20):
    print( " {0:5.3f} {1:5.3f} {2:5.3f} -> {3:2d} : {4:2d}".
          format( predict_proba[i][0], predict_proba[i][1], predict_proba[i][2],
                  predict[i], test_label[i] ) )

print( " [ 予測結果 ]" )
print( classification_report(test_label, predict) )

print( "¥n [ 正解率 ]" )
print( accuracy_score(test_label, predict) )

print( "¥n [ 混同行列 ]" )
print( confusion_matrix(test_label, predict) )
```

各クラスの確率

予測結果

正解ラベル

accuracy
precision
recall
F値

accuracyの表示

混同行列の表示

実行結果①

The screenshot shows a command prompt window with the following output:

```
cal コマンド プロンプト
[ Support Vector ]
0 : 4
1 : 4
2 : 3
[11 25 30 56 18 24 40 43 49 53 63]

setosa versicolor virginica -> 予測結果 : 正解ラベル
0.939 0.040 0.021 -> 0 : 0
0.019 0.793 0.188 -> 1 : 1
0.033 0.606 0.361 -> 1 : 2
0.035 0.515 0.451 -> 2 : 2
0.212 0.766 0.022 -> 1 : 1
0.001 0.007 0.992 -> 2 : 2
0.003 0.043 0.954 -> 2 : 2
0.030 0.934 0.036 -> 1 : 1
0.042 0.565 0.392 -> 1 : 2
0.041 0.932 0.027 -> 1 : 1
0.942 0.040 0.018 -> 0 : 0
0.022 0.765 0.213 -> 1 : 1
0.009 0.104 0.888 -> 2 : 2
0.026 0.367 0.608 -> 2 : 2
0.014 0.907 0.079 -> 1 : 1
```

Annotations with red arrows point to the following elements:

- クラス1のサポートベクターの個数 (Class 1 Support Vector Count) points to the value 4 for class 0.
- クラス2のサポートベクターの個数 (Class 2 Support Vector Count) points to the value 4 for class 1.
- クラス3のサポートベクターの個数 (Class 3 Support Vector Count) points to the value 3 for class 2.
- サポートベクターのデータ番号 (Support Vector Data Number) points to the array [11 25 30 56 18 24 40 43 49 53 63].
- 予測結果 (Prediction Result) points to the predicted class labels (0, 1, 2) in the output rows.
- 正解ラベル (Correct Label) points to the correct class labels (0, 1, 2) in the output rows.
- クラス1の予測確率 (Class 1 Prediction Probability) points to the probability 0.939 for setosa.
- クラス2の予測確率 (Class 2 Prediction Probability) points to the probability 0.040 for versicolor.
- クラス3の予測確率 (Class 3 Prediction Probability) points to the probability 0.021 for virginica.

実行結果②

コマンドプロンプト

[予測結果]

	precision	recall	f1-score	support
0	1.00	1.00	1.00	21
1	0.68	1.00	0.81	23
2	1.00	0.65	0.78	31
accuracy			0.85	75
macro avg	0.89	0.88	0.86	75
weighted avg	0.90	0.85	0.85	75

[正解率]

0.8533333333333334

[混同行列]

[21	0	0]
[0	23	0]
[0	11	20]


accuracy
precision
recall
F値

accuracyの表示

混同行列の表示

SVM Regression (SVR) のプログラム (SVR.py)

■ メキシカンハット関数の学習



$$f(x) = (1 - x^2) \times \exp(-0.5x^2)$$

SVR.py

```
import numpy as np
from sklearn import datasets
from sklearn.model_selection import train_test_split
from sklearn.svm import SVR
from sklearn.metrics import classification_report, accuracy_score,
confusion_matrix
import matplotlib.pyplot as plt

# メキシカンハット関数
data = np.sort(np.random.uniform(-4, 4, 200))
label = ( 1 - data*data ) * np.exp( -0.5 * data * data ) +
        0.1*np.random.normal(size=len(data))

data = data.reshape( (len(data),1) )
```

SVRのために必要

$\text{np.random.uniform}(L, H, N)$
L以上, H未満の一樣乱数をN個生成

$f(x) = (1 - x^2) \times \exp(-0.5x^2)$

$\text{np.random.normal}(N)$
N個の標準正規乱数を生成

(200, 1)の行列に変形

RBFカーネル

```
model = SVR(kernel='rbf', C=10000, gamma=0.1, epsilon=0.1)
```

epsilon:
 ϵ -tubeの長さ

kernel='rbf'
多項式カーネル

Cが小さい→ソフトマージン
Cが大きい→ハードマージン

gamma:
カーネル関数の係数

学習

```
model.fit(train_data, train_label)
```

予測(テストデータ)

```
predict = model.predict(test_data)
```

R2を求める

```
train_score = model.score(train_data, train_label)
```

```
test_score = model.score(test_data, test_label)
```

```
print( "¥n [ R2 ]" )
```

```
print( " 学習データ : {0:7.5f}".format( train_score ) )
```

```
print( " テストデータ: {0:7.5f}".format( test_score ) )
```

散布図の描画

```
fig = plt.figure()
```

```
plt.scatter( test_data , predict , c="red" , label="predict" )
```

予測結果

```
plt.scatter( test_data , test_label , c="blue" , label="data" )
```

実際のデータ

```
plt.xlabel("data")
```

X軸, Y軸の名前

```
plt.ylabel("label")
```

```
plt.legend(loc='upper left')
```

ラベル位置の設定

```
fig.savefig("result.png")
```


ファイルに保存

実行結果

```
コマンドプロンプト

[ R2 ]
学習データ : 0.93959
テストデータ : 0.89713
```


相関係数の二乗



練習問題

■ 二値分類

- SVC-exercise.py を実行して下さい
- 下図(data.png)のように, クラス1(赤点), クラス2(青点)のデータ(二次元データ)を100個ずつ生成します.



*宿題とします. 12/23(月)13時までにkeio.jpにプログラム(python)とワープロに実行画面を貼り付けて提出して下さい.

練習問題

- データは次の配列に格納されています.
 - クラス1のデータ `data[0:100]` ラベル `label[0:100]`
 - クラス2のデータ `data[100:]` ラベル `label[100:]`
- データをホールドアウト法により, 学習データ, テストデータに半分ずつに分けなさい.
- SVMによって学習データを学習し, テストデータのラベルを予測しなさい.
- カーネルについては, RBFカーネル, 多項式カーネルを試し, カーネルの違いによって分類できる, 分類できないことを確認しなさい.

参考文献

- 加藤直樹他：データマイニングとその応用，朝倉書店，2008
- 大北剛訳：サポートベクターマシン入門，共立出版，2005
- 小野田崇：サポートベクターマシン，オーム社，2007
- 平井有三：はじめてのパターン認識，森北出版，2012
- 後藤正幸：入門 パターン認識と機械学習，コロナ社，2014

参考文献

- SVC
- <https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVC.html>
- SVR
- <https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVR.html>